

전처리 절차 정리

목적 03.Preprocessing.ipynb를 열지 않고도 최종 산출물, 처리 흐름, 판단 근거, 검증 결과를 이해하는 문서

범위 LDAPS·VESTAS SCADA·UNISON SCADA 전처리 / GFS·TEST 제외

0. 최종 산출물 명세

한 줄 결론 최종 모델링 표는 `train_merged.csv`이며, 나머지 6개 파일은 원본 추적·집계·공간 비교·품질 검증 용이다.

전처리 산출물 구조

파일	행 × 열	용량	용도
scada_turbine_10min.csv.gz	2,420,148 × 27	63.4 MB	터빈 단위 10분 원본·정제값 + QC 플래그 9종 (감사·재현용)
scada_turbine_hourly.csv	403,368 × 19	56.3 MB	터빈 단위 시간 집계 + 유효 샘플 수
scada_group_hourly.csv	78,912 × 15	8.9 MB	그룹 단위 시간별 발전량·풍속·풍향 + coverage_ratio
ldaps_group_idw.csv	78,912 × 34	21.5 MB	그룹별 공간가중(IDW) LDAPS 피쳐
ldaps_grid_stats.csv	26,304 × 57	12.0 MB	16격자 단순 통계본 (IDW 대조군)
train_merged.csv	78,912 × 120	72.5 MB	최종 결합표 (모델링 노트북 입력)
qc_report.csv	26행	2 KB	계약 검사·LDAPS 품질검사·최종 검증 결과 통합 보고서

- 총 용량: **235 MB**
- 저장 형식: `utf-8-sig`, `float_format="%0.6g"`
- 10분 단위 표만 gzip 압축
- `train_merged.csv` 재로드 결과: **78,912행 × 120열**, 결측률 50% 초과 컬럼 없음
- 모델 입력 원칙: **LDAPS 변수 사용** / `scada_*` 변수는 주 모델 입력 금지

1. 전처리의 최종 설계

1.1 핵심 원칙

- 발전량 0은 결측값으로 처리하지 않음(실제 상태)
- 값을 지우기 전에 이상 원인을 플래그로 기록
- 결측은 20분 이하만 보간, 장기 결측은 유지
- SCADA는 보정·품질진단용, LDAPS는 실제 예측 입력용
- LDAPS 16격자 단순 평균 대신 터빈 위치 기반 IDW 공간가중 적용

1.2 전체 파이프라인

절	단계	핵심 처리	근거 노션 자료
0	환경·상수	임계값 20종을 노트북 상단 상수로 일원화	[04][05][06]
1	원본 로드·계약 검사	3개 파일 로드, 터빈 메타 17기 구성, 구조 검사 13 항목	[06-1단계]
2	시간·단위·컬럼 통일	LDAPS 컬럼 snake 통일, hour_end=ceil, 단위 확정, 10분 축 복원	[06-2.4][06-2.10]
3	결측 확인	터빈별·월별·시간대별 결측률, 05 문서 구간 판정	[05]
4	물리한계 이상치 탐지	SCADA 플래그 9종 생성(값 미변경), LDAPS 구조·물리 검사	[05][06-2.8][06-2.9]
5	이상치 NaN 변환	raw·clean·qc_flag 3컬럼 구조, NaN 처리는 3종만	[06-3단계]
6	결측 패턴 분석	연속 결측 길이 분포, 월·요일·시간대 패턴 검증	[05]
7	단기 보간	20분 이하만 선형보간, 장기 결측은 보존 + 보간 표시	[05][06-2.2]
8	파생변수 생성	격자별 풍속·풍향·공기밀도·풍력에너지밀도, SCADA U·V 변환	[04][06-2.6][06-2.7]
9	시간 단위 집계	min_count 2단계 적용, coverage_ratio 동시 저장	[06-2.2]
10	공간 매핑·결합·검증·저장	IDW 그룹 피쳐 + 단순통계 비교본, 시각 정합 검증, prep/ 저장	[06-2.5][06-5단계]
11	정리	확정 사항·다음 단계 기록	-

2. 결론은 어떻게 도출했는가

2.1 시간 칸: **ceil** + 6개 합계

결론 00:10~01:00 자료는 01:00 칸에 넣고, 발전량은 여섯 값을 합산한다.

- 문제: **floor** 를 쓰면 라벨보다 1시간 앞당겨짐
- 검증: 집계값을 -1·0·+1시간 이동해 공식 라벨과 MAE 비교
- 결과: 세 그룹 모두 0시간 이동의 MAE가 최소

그룹	이동 0시간 MAE	이동 +1시간 MAE	이동 -1시간 MAE	상관계수(0시간)	SCADA÷라벨 증양값
kpx_group_1	130.9 kWh	1,202.1 kWh	1,273.1 kWh	0.9998	1.0148
kpx_group_2	124.7 kWh	1,185.3 kWh	1,266.7 kWh	0.9998	1.0110
kpx_group_3	282.3 kWh	1,020.5 kWh	1,332.5 kWh	0.9967	0.9963

- SCADA 합계는 라벨보다 1.1~1.5% 높음
- 평가기준: 최종 정답은 항상 **KPX** 그룹 사용

2.2 시간 집계: **min_count** 를 두 번 적용

결론 터빈별 10분 자료 6개가 모두 있고, 필요한 터빈 수도 충족할 때만 그룹 발전량을 계산한다.

- 터빈 단계: `min_count=6`
- 그룹 단계: `min_count=터빈 수`
- 이유: 결측을 무시한 합계가 **발전량 0으로 둔갑**하는 오류 방지
- 보조안: 5/6 허용 후 6/n으로 보정한 완화 버전도 저장
- 함께 저장: `coverage_ratio` , `avail_cap_ratio`

2.3 이상치: 삭제보다 상태 구분

결론 물리적으로 불가능한 값 3종만 NaN으로 바꾸고, 운영상 의미가 있는 값은 유지한다.

플래그	판정 기준	건수	비율
<code>is_power_outlier</code>	발전량 > 정격 105%	1,350	0.056%
<code>is_power_neg_large</code>	발전량 < -정격 5%	434	0.018%
<code>is_power_neg_small</code>	-정격 5% ≤ 발전량 < 0	316,787	13.090%
<code>is_frozen_sensor</code>	동일 값 3시간(18스텝) 이상 반복, 0 제외	7,447	0.308%
<code>is_high_wind_zero_power</code>	풍속 5 m/s 이상·컷아웃 미만인데 발전량 0 이하	95,273	3.937%
<code>is_low_wind_zero_power</code>	풍속 컷인(3 m/s) 미만이고 발전량 0 이하	391,611	16.181%
<code>is_cut_out</code>	풍속 ≥ 모델별 컷아웃	999	0.041%
<code>is_ws_out_of_range</code>	풍속 < 0 또는 > 75 m/s	0	0.000%
<code>is_turbine_disagreement</code>	동일 그룹·시각 중앙값과 정격 50% 이상 차이	45,382	1.875%

- NaN 변환: `is_power_outlier` , `is_power_neg_large` , `is_frozen_sensor`
- 값 유지: 작은 음수·고풍속 무발전·저풍속 무발전·컷아웃
- 3열 구조: `power_raw` / `power_clean` / `power_qc_flag`
- 발전량 0인 322,148행은 전부 유지

2.4 결측 보간: 20분 이하만

결론 연속 결측 2스텝(20분) 이하는 선형보간하고, 그보다 긴 구간은 비워 둔다.

- 연속 결측 구간: 1,295개
- 20분 이하: 962개 / 20분 초과: 333개
- 보간: 발전량 1,165건, 풍속 247건
- 장기 결측을 채우면 통신장애·정비 정지를 실제 저발전으로 잘못 학습
- 풍향은 각도 그대로 보간하지 않고 U·V 성분으로 변환 후 처리

2.5 LDAPS 품질검사: 통계적 극단값을 지우지 않음

결론 LDAPS에는 IQR·3σ 제거를 적용하지 않고, 구조·물리 일관성만 검사한다.

- LDAPS는 센서 관측값이 아니라 **수치예보 모델 결과**
- 폭풍·급변은 극단값이지만 예측에 중요한 사례

- 미통과 값도 유지하고 플래그로 기록

2.6 비선형 계산: 격자별 계산 후 평균

결론 풍속³·공기밀도·풍력에너지밀도는 16격자를 먼저 평균하지 않는다.

- (평균 풍속)³ : 216.0
- 평균(풍속³) : 227.2
- 평균을 먼저 내면 발전 가능 에너지를 **4.9% 과소평가**
- 처리: 격자별 파생변수 계산 → IDW 공간가중

2.7 공간 매핑: 최근접 4격자 IDW

결론 각 터빈에서 가까운 4개 LDAPS 격자를 골라 거리가 가까울수록 큰 가중치를 준다.

- 거리: haversine
- 가중치: $1 / \text{거리}^2$, 합계가 1이 되도록 정규화
- 터빈 피쳐 생성 후 설비용량 가중으로 그룹 집계
- 결과: 26개 피쳐, 78,912행 × 34열

그룹	평균 풍속(m/s)	평균 공기밀도(kg/m³)	가중 지표고도(m)
kpx_group_1	4.9039	1.1154	993.47
kpx_group_2	5.0767	1.1156	988.42
kpx_group_3	5.1344	1.1176	968.29

3. 단계별 전처리 절차

3.0 환경·상수

- 경로: `TRAIN_DIR`, `INFO_DIR`, `PREP_DIR`
- 임계값 20종을 노트북 상단 한 곳에서 관리

3.1 원본 로드·계약 검사

- 입력 3개: LDAPS 420,864행 / VESTAS 157,819행 / UNISON 105,264행
- 터빈 메타: 17기, 3개 KPX 그룹
- 계약 검사 13항목: 전부 통과
- 미래 정보 사용 없음: `data_available ≤ forecast` 전건 성립
- LDAPS: 매 시각 16격자, 시간축 빈틈 없음

3.2 시간·단위·컬럼 통일

- LDAPS 컬럼 30종을 짧은 snake case로 변경
- `hour_end = ceil('1h')`

- 예보 구조 보존: `forecast_issue_date`, `lead_hour`, `target_hour`
- SCADA 10분 완전 인덱스 생성 후 재색인

컬럼	단위	실측 범위	판정
t2m (기온)	K	249.70 ~ 302.92	정상
dpt2m (이슬점)	K	242.41 ~ 297.35	정상
q2m (비습)	kg/kg	0.0002 ~ 0.0212	정상 (g/kg 아님)
sp (지표기압)	Pa	87,462.81 ~ 93,083.13	정상 (hPa 아님)
surface_h (지표고도)	m	868.81 ~ 1,001.25	정상 (태백 산지)
rh2m (상대습도)	%	11.02 ~ 110.38	100% 초과 존재 → 4절 플래그

3.3 결측 확인

- long 형식: 한 행 = 터빈 1기 × 시각 1개
- 총 2,420,148행
- VESTAS 결측 0.00% / UNISON 0.13~1.29%
- 그룹3의 2022년은 결측이 아니라 데이터가 존재하지 않는 기간

3.4 물리한계 이상치 탐지

- SCADA 플래그 9종 생성
- 이 단계에서는 값을 바꾸지 않음
- LDAPS는 구조 검사 + 물리 일관성 검사

3.5 이상치 NaN 변환

- 원본·정제·QC 비트 코드로 분리
- `power_raw` 결측 2,214건 → `power_clean` 결측 11,011건
- 풍향은 -180~180을 0~360으로 통일

3.6 결측 패턴 분석

- 중앙값 1스텝(10분), 최대 430스텝(약 3일)
- 주간 0.38% / 그 외 0.50%: 정비 시간 집중은 뚜렷하지 않음

3.7 단기 보간

- 20분 이하만 선형보간
- 보간 위치를 별도 플래그로 저장

3.8 파생변수

- 풍속: $\sqrt{(u^2+v^2)}$
- 풍향: `atan2` 로 계산, sin·cos도 저장
- 공기밀도·풍력에너지밀도 계산

- SCADA 풍향은 U·V로 분해 후 보간
- 이론 출력은 참고 지표이며 실제 출력과 정비례를 강제하지 않음

3.9 시간 단위 집계

- 발전량: 합계
- 풍속: 평균
- 풍향: U·V 평균 후 방향 복원
- 터빈×시간: 403,368행 / 그룹×시간: 78,912행
- 평균 설비이용률: 0.306 / 0.328 / 0.236

3.10 공간 매핑·결합·저장

- IDW 피쳐와 16격자 단순통계본을 모두 저장
- 시간 파생: 시각·연중일 sin/cos, 월·계절, 변화량·램프율
- 결합 기준: (시각, 그룹)
- 최종 결합표: 78,912행 × 120열

4. 검증 결과

4.1 최종 검증 7항목 전부 통과

검사항목	결과	내용
시각 정합(이동 0시간 최적)	통과	그룹별 최적 이동 = 0시간 / 0시간 / 0시간
그룹3 2022년 공백 유지	통과	2022년 8,759행 전부 NaN (0 채움 없음)
공기밀도 0.9~1.4 kg/m ³	통과	1.0232 ~ 1.2543
행 수 = 시각 × 그룹	통과	78,912행 (기대값 78,912)
(시각, 그룹) 중복 없음	통과	결합 과정 행 증식 없음
그룹별 LDAPS 풍속 분리	통과	4.9039 / 5.0767 / 5.1344 m/s
설비이용률 ≤ 105%	통과	최대 1.004

4.2 LDAPS 품질검사 통과 4 / 미통과 2

검사항목	결과	내용	처리 방침
NaN·Inf 없음	통과	NaN 0개 / Inf 0개	
기온 ≥ 이슬점	미통과	위반 6,398건	값 유지 + is_temp_below_dew 플래그
상대습도 0~100%	미통과	100% 초과 16,649건, 최대 110.4%	값 유지 + is_rh_over_100 플래그
기압 범위	통과	87,463 ~ 93,083 Pa	
비습 범위	통과	0.00024 ~ 0.02125 kg/kg	
육지/해양 마스크	통과	lsm 전부 1 (전 격자 육지)	

- 미통과 2종도 삭제하지 않고 플래그 유지
- 모델링에서 피쳐 또는 표본 가중치로 활용 가능

4.3 데이터 계약 검사

- 13항목 전부 통과
- 중복·격자 수·좌표 불변·예보 사용 가능 시각·시간축 검증 완료

5. 데이터에서 확인된 특이사항

- VESTAS 결측 0건이지만 정격 초과 극단값 1,350건 존재
- 작은 음수 발전량 316,787건(13.09%): 대기·보조전력 가능성
- U136의 단순 Cp 추정은 베츠 한계를 자주 초과 → 풍속³ 비율을 효율로 직접 해석 금지
- 격자 간 풍속 편차: 중앙값 2.21 m/s, 최대 10.62 m/s
- 고풍속 무발전 95,273건(3.94%): 고장·정비·출력제한 후보
- SCADA 시간축 누락은 실제로 없음

6. 임계값 일람

상수	값	의미	근거
R_D	287.05 J/(kg·K)	건조공기 기체상수	[04][기상청-대기역학]
EPSILON	0.62197	건조공기/수증기 기체상수 비	[04]
POWER_CAP_RATIO	1.05	정격 105% 초과 시 센서 오류 판정	[06-2.8][01]
NEG_POWER_RATIO	0.05	큰 음수/작은 음수 구분 기준	[06-2.8]
FROZEN_STEPS	18 (3시간)	센서 고착 판정 반복 횟수	[06-2.8]
CUT_IN_MS	3.0 m/s	컷인 풍속 (V126·U136 공통)	[스펙]
CUT_OUT_MS	V126 22.5 / U136 22.0 m/s	컷아웃 풍속	[스펙]
HIGH_WS_MS	5.0 m/s	고풍속 무발전 판정 하한	[06-2.8]
WS_PHYS_MAX	75 m/s	풍속 물리한계 상한	[기상청-품질검사]
DISAGREE_RATIO	0.5	터빈 간 불일치 판정(정격 대비)	[06-2.8]
LOW_WS_MASK	1.0 m/s	방향 통계 제외 기준 풍속	[06-2.7]
MIN_SAMPLES_PER_HOUR	6	시간 합계 인정 최소 샘플 수	[06-2.2]
MIN_SAMPLES_RELAXED	5	완화 버전 최소 샘플 수	[06-2.2]
MAX_INTERP_STEPS	2 (20분)	선형보간 허용 최대 연속 결측	[05][06-2.2]
IDW_K	4	터빈별 사용 격자 수	[06-2.5]
IDW_POWER	2.0	역거리 가중 지수	[06-2.5]
SWEPT_AREA_M2	V126 12,469 / U136 14,470 m ²	수풍면적	[스펙]

상수	값	의미	근거
GROUP_CAP_KWH	21,600 / 21,600 / 21,000	그룹별 1시간 설비용량(kWh)	[명세][정보]

수풍면적은 원형 면적 추정값이 아니라 스펙 시트의 실측값을 사용한다.

7. 다음 단계

- LSTM용 시계열 전처리 절차 추가
- LDAPS 10 m 풍속 → 허브 높이 117 m 현장풍속 보정
- 보정값을 주 모델에 쓸 경우 시계열 OOF 예측값 사용
- 그룹별 정상 파워커브와 `power_residual` 산출
- A/B 비교
 - IDW 공간가중 vs 16격자 단순통계
 - 6/6 엄격 집계 vs 5/6 완화 집계
 - 낮은 coverage 구간 포함 vs 제외
 - 발전량 원값 vs capacity factor
- 검증: 과거 연도 학습 → 2024년 검증
- 선택 지표: 상관계수보다 **1-NMAE·FICR**
- 최종 예측값 범위 제한: 0~그룹별 설비용량
- GFS 80-100 m 바람은 후속 검토

8. 출처

8.1 검토 문서

코드	자료	본문에서 인용한 내용
[04]	MD/04._전처리_방법론_고민(기상요소).pdf	u·v ↔ 풍속·풍향 벡터 변환, atan2 사용 근거, 풍향 변환 검증표, 이상 기체 상태방정식 기반 습윤공기 밀도 유도, 비습→수증기압 변환식, 발전량 공식 $P = \frac{1}{2}\rho A V^3 C_p$
[05]	MD/05._전처리_방법론_고민(ldaps_데이터).pdf	기상기후 품질검사 알고리즘의 물리한계 개념, ASOS·AWS와 LDAPS의 품질검사 목적 차이, 결측률 구간별 처리 가이드
[06]	MD/06._데이터_파이프라인_개선.pdf	권장 전처리 파이프라인 10단계, 개선점 2.1~2.12, 현재 코드에서 바로 수정할 다섯 가지. 본문에서는 [06-2.2]처럼 절 번호까지 표기

8.2 사용한 자료

코드	자료	본문에서 인용한 내용
[명세]	MD/data_description.md	파일 구성·행 수·기간, utf-8-sig 인코딩, 예보 발행 구조(09시 초기화·13시 사용 가능), 라벨 시각 정의(집계 종료 시각), 그룹별 설비용량, 평가 기간 SCADA 미제공
[공지]	MD/Notices.md	대회 개요, 평가지표 1-NMAE 및 FICR, 데이터 사용 범위

코드	자료	본문에서 인용한 내용
[컬럼]	MD/TRAIN_컬럼_설명.docx	TRAIN 폴더 컬럼 정의, 터빈 → KPX 그룹 매핑 (본 문서 서식 기준)
[정보]	INFO/info.xlsx	터빈 17기의 KPX 그룹·좌표·허브 높이·로터 직경·설비용량
[스펙]	INFO/V126_vs_U136_스펙비교.html	컷인 3 m/s, 컷아웃 V126 22.5 / U136 22.0 m/s, 수풍면적 12,469 / 14,470 m ² , 정격 출력

8.3 외부 기술 근거

코드	자료	본문에서 인용한 내용
[기상청-표준규격]	기상청 「자동기상관측장비의 표준규격」 제9조 관련 별표4 (개정 2023.3.6.)	풍향·풍속은 벡터 환산 후 산출. 각도 단순 산출평균 금지 근거
[기상청-예보관]	기상청 예보관 훈련용 기술서 수치예보 / 기상청 현업 시스템 (middle_04_1.pdf)	수치예보 모델의 10 m 바람 U·V 자료를 수정 없이 사용, 한반도 영역에서 지도투영 왜곡 무시 가능
[기상청-대기역학]	기상청 대기역학 교재 (식 3.17~3.22)	습윤공기 상태방정식, 가온도 정의, 건조공기 기체상수 287.05
[기상청-품질통계]	기상관측데이터 품질 통계 관리지침 (2025.9)	기후통계 산출 방법(합계·평균·극값), 자료 누락 시 미산출 원칙
[기상청-품질검사]	기상기후 품질검사 알고리즘 물리한계 기준표 (ASOS·AWS)	풍속 0~75 m/s, 풍향 0~360° 등 물리한계 범위
[기상청-LDAPS]	통합모델 기반 국지예보시스템(LDAPS) 제원 UM 1.5km L70	수평해상도 1.5 km, 일 4회 48시간 예측, 예측간격 1시간
[기상청-영상]	기상청 유튜브 (https://youtu.be/5GEPRBvejv4)	이상치 검출 방법, 결측치 처리·대체 방법
[Hair]	Hair et al. (2006), pp.49-73	결측률 구간별 처리 가이드 (10% 미만 / 10~20% / 20% 이상 / 50% 이상 미사용)
[블로그]	https://randroll.wordpress.com/2022/05/03/wind-direction-from-wind-components/	바람 성분에서 풍향 계산 방법 (atan2 활용)

8.4 프로젝트 코드

코드	파일	관계
[01]	01.data_nogada.ipynb	SCADA 탐색, 터빈-그룹 매핑 로직, 105% 이상치 기준, 월별·계절 패턴 확인 (본 전처리의 선행 분석)
[02]	02_Aggregation.ipynb	격자·터빈 단위 1차 집계, agg/ 산출물 (본 전처리의 이전 버전)
[03]	03.Preprocessing.ipynb	본 문서가 정리 대상으로 삼은 전처리 노트북