

# 06. 데이터 파이프라인 개선

## 가장 큰 개선 포인트

1. SCADA를 모델 입력이 아니라 LDAPS 보정·품질진단용 데이터로 재정의
2. LDAPS 16개 격자를 전체 평균하지 말고 KPX 그룹별 공간 특성으로 변환
3. 결측·정지·출력제한·센서 오류를 모두 같은 이상치로 취급하지 않도록 구분

- 대회 테스트 데이터에는 LDAPS와 GFS만 있고 SCADA는 제공되지 않음
- 예측 시점의 SCADA를 입력값으로 사용하는 구조는 실제 제출 단계에서 재현할 수 없음.
- SCADA는 학습 기간 동안의 **기준값**으로 활용

## 1. 현재 파이프라인 진단

### 현재까지 해본 것

- 터빈별 10분 발전량을 시간 단위로 합산
- 풍속을 시간·터빈 기준으로 평균
- 풍향을 단순 산술평균하지 않고  $\sin \cdot \cos$  기반 원형 평균으로 계산
- 발전량이 정격의 105%를 초과하면 이상치로 처리
- LDAPS의 U·V 성분으로 풍속과 기상학적 풍향 계산
- 비습·기압·기온으로 습윤공기 밀도 계산

### 현재 구조의 근본적 문제

현재 분석은 상당 부분 다음 관계를 확인하는 데 집중

| SCADA 풍속 → SCADA 발전량

실제 모델이 풀어야 하는 문제

| LDAPS 예보 → 미래 KPX 발전량

- LDAPS를 발전소 현장 풍속, 풍향으로 변환하는 것이 더 중요

## 2. 우선순위별 개선점

### 2.1 SCADA 집계값과 공식 발전량 라벨의 단위·시각 검증

- 현재 코드에서는 `power_kw10m` 을 10분 발전 에너지로 보고 6개 값을 더해 시간별 kWh로 변환
- 데이터 형태상 타당해 보이지만, 컬럼명 자체는 `kw10m` 이어서 해석이 모호함
- 공식 라벨은 1시간 집계 종료시각 기준의 kWh
- 따라서 다음 조합을 실제 `train_labels.csv` 와 비교
- 시간 정렬: `ceil`, `floor`,  $\pm 1$ 시간 이동
- 단위 변환: `sum`, `mean`, `sum ÷ 6`
- 평가값: MAE, 상관계수, `SCADA 합계 ÷ 공식 라벨` 중앙값

가장 오차가 작은 조합을 공식 집계 규칙으로 확정할 필요가 있음

- 주의할 것: 시간 경계가 한 시간만 어긋나도 모델은 정상적으로 학습되는 것처럼 보이지만 성능 상한이 크게 낮아진다.
- 목표: 이후 모든 특성·라벨의 시간 정합성 확보

### 2.2 결측치 발전량 0으로 바뀌는 집계 오류 수정

현재 코드는 다음 구조입니다.

```
power_hourly = (  
    df.groupby("hour_end")[power_cols]  
    .sum(min_count=1)
```

```

        .sum(axis=1)
    )

```

여기에는 두 가지 문제가 있습니다.

첫째, 특정 터빈에 10분 자료가 한두 개만 있어도 이를 정상적인 1시간 발전량으로 사용합니다.

둘째, 모든 값이 결측인 터빈은 첫 번째 합계에서 NaN이 되지만, 두 번째 `sum(axis=1)` 에서 NaN이 무시되어 그룹 발전량이 과소 계산됩니다. 모든 터빈이 결측이어도 0이 될 수 있습니다.

다음 정보를 별도로 만들어야 합니다.

- 터빈별 시간당 유효 샘플 수
- 그룹 전체 유효 샘플 비율
- 데이터가 존재하는 터빈의 설비용량 비율
- 완전 결측 여부
- 부분 결측 여부

권장 원칙은 다음과 같습니다.

```

# 터빈별로 6개 10분값이 모두 있을 때만 시간 합계 인정
power_by_turbine = (
    df.groupby("hour_end")[power_cols]
    .sum(min_count=6)
)

# 그룹 합계도 필요한 터빈 수를 충족할 때만 계산
group_power = power_by_turbine.sum(
    axis=1,
    min_count=len(power_cols)
)

```

다만 무조건 완전자료만 남기기보다 `coverage_ratio` 를 함께 저장하고, 5/6 이상 허용 여부를 검증 데이터에서 비교하는 편이 좋습니다.

**단기 영향:** 일부 행이 NaN으로 늘어남

**장기 영향:** 통신 장애를 실제 저발전으로 학습하는 오류 방지

**예상 결과:** 저출력 구간 예측 편향 감소

확신도: 높음

## 2.3 학습·테스트에서 동일하게 만들 수 있는 변수만 모델 입력으로 사용

SCADA는 학습 기간에만 제공되고, 평가 기간에는 제공되지 않습니다.

따라서 변수는 세 종류로 분리해야 합니다.

| 구분              | 용도                          |
|-----------------|-----------------------------|
| 공식 KPX 발전량      | 최종 모델의 정답값                  |
| SCADA 발전량·풍속·풍향 | LDAPS 보정, 파워커브 추정, 이상 상태 분석 |
| LDAPS 변수        | 최종 예측 모델의 실제 입력값            |

SCADA 풍속이나 SCADA 발전량을 최종 학습표에 그대로 넣으면 학습 성능은 매우 높아지지만 테스트에서는 생성할 수 없습니다.

SCADA로 학습한 `LDAPS → 현장풍속 보정 모델`을 주 모델의 입력으로 사용할 경우에도, 학습 데이터에는 **Out-of-Fold 예측값**을 생성해야 합니다. 전체 기간을 이용해 보정 모델을 학습한 뒤 동일 기간을 다시 예측하면 간접적인 데이터 누수가 생깁니다.

확신도: 높음

## 2.4 예보일의 시간 범위 재정의

현재 문서에서는 D-1일 14시 이전 자료로 예측일 00~23시를 예측하는 것으로 정리되어 있습니다.

하지만 공식 데이터는 다음 구조입니다.

- 예보 초기화: 09:00
- 사용 가능 시각: 13:00
- 대상 시각: 다음날 01:00부터 그다음 날 00:00까지
- 24개 대상 시각이 같은 `data_available_kst_dtm`을 공유

따라서 임의로 달력 날짜의 00~23시로 재배치하지 말고 다음 값을 명시적으로 유지해야 합니다.

- `forecast_kst_dtm`
- `data_available_kst_dtm`
- `forecast_issue_date`
- `lead_hour`

- `target_hour`

14시는 내부적으로 안전 여유시간으로 사용할 수 있지만, 데이터의 공식 사용 가능 시각은 13시입니다.

**숨겨진 리스크:** 00시 자료를 잘못된 예보 발행일에 연결하거나 24시간 묶음이 하루씩 이동하는 문제

**확신도:** 높음

## P1. 예측 정확도에 가장 큰 영향을 줄 개선점

### 2.5 LDAPS 16개 격자의 단순 평균 중단

현재 코드는 모든 16개 격자의 풍속과 풍향을 하나의 평균값으로 만든 뒤 세 그룹 모두에 동일하게 적용합니다.

이 방식은 다음 정보를 잃습니다.

- 각 KPX 그룹과 격자 사이의 거리
- 지형 고도 차이
- 풍향에 따른 산악 지형 영향
- 그룹별 바람장 차이
- 16개 격자 사이의 공간적 불확실성

`info.xlsx`에는 터빈 좌표, KPX 그룹, 허브 높이, 로터 직경, 설비용량이 제공됩니다.

따라서 다음 순서로 바꾸는 것이 좋습니다.

1. 터빈별 위치와 16개 LDAPS 격자 간 거리 계산
2. 터빈마다 가까운 4개 격자 선정
3. 역거리 가중평균 또는 bilinear interpolation
4. 터빈별 예보변수 생성
5. 설비용량 또는 로터 면적을 가중치로 그룹 집계

추가로 다음 공간 통계도 보존합니다.

- 그룹 주변 풍속 평균
- 최솟값·최댓값
- 표준편차

- 25~75% 분위수
- 격자 간 U·V 범위
- 고도 차이

**단기 영향:** 피쳐 수와 구현 복잡도 증가

**장기 영향:** 그룹별 국지 지형과 바람 특성 반영

**예상 결과:** 세 그룹에 동일한 LDAPS 풍속을 넣는 현재 구조보다 성능 향상 가능성이 가장 큼

**확신도:** 높음

## 2.6 10m 예보풍속을 허브 높이 풍속으로 보정

LDAPS의 기본 바람은 10m 높이이고, 실제 터빈은 더 높은 허브에서 작동합니다. 현재 분석에서 LDAPS 풍속의 설명력이 SCADA 풍속보다 크게 낮은 핵심 원인 중 하나입니다.

단순한 고정 지수의 멍법칙만 적용하기보다 다음 방식이 더 적합합니다.

### 1단계: 간단한 기준 모델

LDAPS 10m 풍속 → 그룹별 선형 또는 비선형 보정 → SCADA 풍속

### 2단계: 보정 변수 추가

- LDAPS 10m U·V
- 50m U·V 최대·최소값
- 경계층 높이
- 기온·기압·비습
- 지표 고도
- 월·시간
- 풍향
- 예보 선행시간

LDAPS에는 10m 바람뿐 아니라 50m U·V 최대·최소, 경계층 바람, 기온, 습도, 기압, 경계층 높이 등이 들어 있습니다.

주의할 점은 `50MUmax` 와 `50MVmax` 를 직접 결합해 하나의 최대 풍속 벡터로 만들면 안 된다는 것입니다. 두 최댓값이 동일 시점에 발생했다는 보장이 없기 때문입니다. 이 값들은 다음처럼 사용하는 편이 안전합니다.

- `u50_range = Umax - Umin`
- `v50_range = Vmax - Vmin`
- 바람 변동성·난류 대리변수

**숨겨진 리스크:** 고정 풍속고도 보정계수는 계절·안정도·풍향에 따라 편향될 수 있음

**확신도:** 중간~높음

## 2.7 풍향은 각도보다 U·V 성분을 중심으로 유지

현재 원형 평균은 맞지만, 최종 모델에는 풍향 각도 하나만 넣기보다 다음 형태를 유지하는 것이 좋습니다.

- `wind_u`
- `wind_v`
- `wind_speed`
- `wind_dir_sin`
- `wind_dir_cos`

SCADA 풍향도 각도 상태에서 평균하기보다 먼저 터빈별 U·V로 변환하는 것이 구조적으로 깔끔합니다.

기상학적 풍향이 바람이 **불어오는 방향**이라면:

```
rad = np.deg2rad(wd)
u = -ws * np.sin(rad)
v = -ws * np.cos(rad)
```

그룹 단위에서는 다음 두 풍속을 모두 보존하는 것이 좋습니다.

- `mean_scalar_ws`: 각 터빈 풍속의 평균
- `vector_mean_ws`: 평균 U·V 벡터의 크기

또한 다음 값을 추가할 수 있습니다.

- `direction_resultant_length`: 풍향이 얼마나 일정한지
- `ws_std`: 터빈·격자 간 풍속 편차
- `direction_spread`: 풍향 분산

풍속이 0에 가까울 때 풍향은 의미가 약하므로, 풍향 평균은 풍속으로 가중하거나 저풍속 풍향을 별도로 마스킹하는 것이 좋습니다.

**확신도: 높음**

## 2.8 SCADA 이상치를 '값의 크기'만으로 판단하지 않기

현재 발전량 절댓값이 정격의 105%를 넘으면 NaN으로 처리합니다.

이 처리는 필요한 것으로 보입니다. 실제로 VESTAS 터빈에는 수십 개의 초과값이 있고 UNISON 5호기는 294개가 검출됐습니다.

다만 다음 상태를 구분해야 합니다.

| 상태                   | 권장 처리                 |
|----------------------|-----------------------|
| 비현실적으로 큰 발전량         | 결측 처리                 |
| 큰 음수값                | 센서·단위 오류 여부 확인        |
| 작은 음수값               | 대기전력·보조전력 가능성, 별도 플래그 |
| 풍속도 낮고 발전량 0         | 정상 정지 가능              |
| 풍속은 높는데 발전량 0        | 고장·정비·출력제한 후보         |
| 일정 값이 장시간 반복         | 센서 고착 후보              |
| 한 터빈만 주변 터빈과 급격히 불일치 | 개별 장비 이상 후보           |

특히 `발전량 0` 을 결측치로 바꾸거나 보간하면 안 됩니다. 고풍속·무발전은 실제 운영정지나 출력제한을 나타낼 수 있기 때문입니다.

권장 플래그:

- `is_power_outlier`
- `is_frozen_sensor`
- `is_high_wind_zero_power`
- `is_low_wind_zero_power`
- `is_partial_missing`
- `is_turbine_disagreement`

이상치를 삭제하기 전에 플래그를 남겨야 분석과 재현이 가능합니다.



확신도: 높음

---

## 2.9 LDAPS에는 일반적인 IQR 이상치 제거를 적용하지 않기

첨부 문서에서 지적했듯이 AWS·ASOS는 센서 관측자료이고, LDAPS는 수치예보 모델 결과이므로 품질검사 목적이 다릅니다. LDAPS에서는 센서 이상치보다 파일 손상, 시간·격자 불일치, 단위 오류, 비물리적 값이 핵심입니다.

LDAPS 품질검사는 다음 순서가 적절합니다.

1. `(forecast_kst_dtm, grid_id)` 중복 확인
2. 대상 시각마다 16개 격자 존재 여부
3. 위도·경도와 grid ID의 일관성
4. `data_available_kst_dtm ≤ forecast_kst_dtm`
5. NaN·Inf 검사
6. 물리적 일관성 검사
  - 기온  $\geq$  이슬점
  - 상대습도 범위 확인
  - 기압·비습 단위 확인
7. 시간·공간 급변값은 삭제하지 않고 플래그 처리

폭풍이나 급격한 기상 변화는 극단값이지만 발전량 예측에서 가장 중요한 사례일 수 있습니다. 따라서 단순 IQR이나  $3\sigma$  규칙으로 제거하면 오히려 모델이 중요한 구간을 학습하지 못합니다.

확신도: 높음

---

## P2. 물리 피처 개선

### 2.10 공기밀도는 유지하되 우선순위를 낮추기

현재 비습으로 수증기압을 계산하고, 기압과 기온을 이용해 습윤공기 밀도를 계산하는 식은 방향상 적절합니다.

다만 반드시 먼저 다음 단위를 확인해야 합니다.

- 기온: K인지 °C인지
- 비습: kg/kg인지 g/kg인지

- 기압: Pa인지 hPa인지
- 계산된 공기밀도: 대체로 현실적인 범위인지

공기밀도는 **각 격자에서 먼저 계산하고 이후 공간 가중평균**하는 것이 좋습니다. 평균 기온·평균 기압으로 밀도를 한 번 계산하는 방식은 비선형 변환에서 오차가 생길 수 있습니다.

추가 피쳐:

```
wind_power_density = 0.5 × air_density × wind_speed3
```

단, 실제 발전량이 이 값에 정비례한다고 강제하기보다 모델 입력변수로 사용하는 편이 안전합니다.

**예상 효과:** 소폭 또는 계절별 성능 개선

**확신도:** 중간

## 2.11 발전량 ÷ 풍속<sup>3</sup> 을 터빈 효율로 바로 해석하지 않기

현재 노트북에서는 **발전량 / 풍속<sup>3</sup>** 을 풍향별 효율로 보고 후류 효과를 판단하고 있습니다.

하지만 이 값에는 다음이 모두 섞입니다.

- cut-in 이하 정지
- 정격출력 구간의 출력 포화
- cut-out 정지
- 피치 제어
- 출력제한
- 고장·정비
- 공기밀도
- 후류
- 예보·센서 오차

따라서 다음 방식으로 바꾸는 것이 좋습니다.

### 1. 그룹별 정상 파워커브 추정

```
expected_power = f(wind_speed)
```

### 2. 실제 발전량과 기대 발전량의 차이 계산

```
power_residual = actual - expected
```

3. 비슷한 풍속 구간 안에서 풍향별 residual 비교
4. 풍향에 따라 반복적인 음의 residual이 나타나는지 확인

즉, 후류 효과는 **발전량/풍속<sup>3</sup>보다 동일 풍속 조건에서의 기대 발전량 대비 잔차**로 판단해야 합니다.

**확신도: 높음**

## 2.12 평균값 외에 분포와 변화량을 보존

풍력에너지는 풍속의 세제곱에 영향을 받으므로, 평균 풍속 하나로 모든 격자를 요약하면 정보 손실이 큼니다.

예를 들어 다음 두 상황은 평균 풍속은 같지만 발전 가능 에너지가 다릅니다.

- 모든 격자가 8m/s
- 절반은 4m/s, 절반은 12m/s

따라서 그룹별로 다음 피처를 생성하는 것이 좋습니다.

### 풍속 수준

- `ws_mean`
- `ws_median`
- `ws_min` , `ws_max`
- `ws_std`
- `ws_q25` , `ws_q75`
- `mean_ws2`
- `mean_ws3`
- `mean_rho_ws3`

### 예보 시간 변화

- 1시간 풍속 변화량
- 3시간 풍속 변화량
- 다음 3시간 최대·최소
- 풍속 램프율

- U·V 변화량
- 풍향 회전속도

#### 시간 정보

- 시간 sin·cos
- 연중일 sin·cos
- 월
- 계절
- 예보 선행시간

풍력 발전량의 월별 패턴이 반복된다는 기존 분석도 계절 피처의 필요성을 뒷받침합니다.

**확신도: 중간~높음**

---

## 3. 권장 전처리 파이프라인

### 1단계. 데이터 계약 검사

- 파일별 필수 컬럼 검사
- 시간형식과 KST 기준 통일
- 중복 시각·중복 격자 검사
- 단위 확인
- 공식 라벨의 시간 범위와 그룹별 제공 기간 확인
- 그룹 3의 2022년 라벨은 결측 그대로 제외

그룹 3은 2023년부터 라벨이 제공되므로 2022년 값을 채우거나 0으로 처리하면 안 됩니다.

---

### 2단계. SCADA 10분 시간축 복원

터빈 제작사별로 완전한 10분 시간 인덱스를 생성하고 `reindex` 합니다.

- 누락 시각
- 중복 시각
- 연속 결측 길이
- 터빈별 결측률
- 시간별 가용 터빈 수

- VESTAS 행 수는 157,819개로, 완전한 시간축과 비교해 누락 시각이 존재할 가능성이 있음
- 명시적인 시간축 검사가 필요

### 3단계. SCADA 품질 플래그 생성

- 물리 범위
- 정격 초과
- 음수 발전량
- 센서 고착
- 고풍속 무발전
- 터빈 간 불일치
- 부분 결측

원본 컬럼은 유지하고 정제값을 별도 컬럼으로 만듭니다.

```
power_raw
power_clean
power_qc_flag
```

### 4단계. 시간별 SCADA 집계

- 발전량: 합계
- 풍속: 평균·표준편차·최대·분위수
- 풍향: U·V 기반 집계

- 그룹 발전량: 터빈별 시간 합계 후 그룹 합계
- 결측률과 가용 설비용량 비율 함께 저장

## 5단계. 공식 라벨과 SCADA 정합성 검증

- 시각 이동 후보 비교
- 단위 환산 후보 비교
- 그룹별 차이 분석
- SCADA와 라벨의 차이를 운영 손실 또는 집계 차이로 분리

최종 학습 정답은 항상 공식 `train_labels.csv`를 사용합니다.

## 6단계. LDAPS 구조적 품질검사

- 매 시각 16개 격자 확인
- 좌표 불변성 확인
- 사용 가능 시각 검증
- 물리·단위 검사
- 결측 격자 플래그

LDAPS는 약 1.5km 공간해상도의 16개 격자로 제공됩니다.

## 7단계. 터빈·그룹별 공간 매핑

LDAPS 격자

- 터빈별 거리 가중 보간
- 터빈별 기상 피쳐
- 설비용량 가중 그룹 피쳐

단순 전체 평균과 비교하여 검증 성능으로 선택합니다.

## 8단계. 현장풍속 보정

SCADA가 존재하는 학습 기간에서 다음 모델을 만듭니다.

그 결과를 `corrected_hub_ws` 로 사용합니다. 학습 구간에는 시계열 OOF 방식으로 생성하고, 테스트에는 전체 학습기간으로 학습한 보정 모델을 적용합니다.

## 9단계. 발전량 모델용 피쳐 생성

### 핵심 피쳐

- 보정 풍속
- U·V 성분
- 풍속 제곱·세제곱
- 공기밀도
- 풍력에너지 밀도
- 공간 분산
- 풍향 일관성
- 시간·계절
- 예보 선행시간
- 경계층 높이
- 기온·비습·기압
- 강수·운량

목표값은 발전량 자체보다 다음처럼 설비용량으로 정규화할 수도 있습니다.

```
capacity_factor = hourly_generation_kWh / hourly_capacity_kWh
```

그룹별 1시간 설비용량은 21,600, 21,600, 21,000kWh입니다.

## 10단계. 시계열 검증과 후처리

- 그룹 1·2: 2022~2023 학습 → 2024 검증
- 그룹 3: 2023 학습 → 2024 검증
- 필요하면 월 단위 rolling validation 추가

전처리 선택 기준도 상관계수가 아니라 대회 실제 지표인 **1-NMAE** 와 **FICR** 로 해야 합니다.  
최종 예측값은 반드시 다음 범위로 제한

```
prediction = prediction.clip(
    lower=0,
    upper=group_hourly_capacity_kwh
)
```

## 4. 현재 코드에서 바로 수정할 다섯 가지

1. `sum(axis=1)` 에 `min_count` 와 시간당 표본 수 기준 추가
2. 16개 LDAPS 격자 전체 평균을 그룹별 거리 가중 집계로 변경
3. 풍향 각도 평균 대신 U·V 집계 후 방향 복원
4. SCADA 풍속을 최종 모델 입력에서 제외하고 LDAPS 보정용으로 이동
5. `power/ws3` 효율을 파워커브 잔차 기반 효율로 변경

## 5. 구현 순서

다음 네 모델을 순서대로 비교

| 모델         | 입력                        |
|------------|---------------------------|
| Baseline A | LDAPS 16개 단순 평균 풍속 + 시간   |
| Baseline B | 그룹별 공간 가중 LDAPS 피쳐        |
| Baseline C | 공간 가중 + SCADA 기반 현장풍속 보정  |
| Baseline D | C + 공기밀도·공간분산·경계층·파워커브 피쳐 |

이 구조라면 각 전처리가 실제 NMAE와 FICR을 얼마나 개선했는지 분리해서 확인할 수 있습니다.

- 가장 큰 영향을 미칠 요인은 **LDAPS의 공간·높이 편향을 그룹별로 보정하는 능력**입니다.



- LDAPS와 SCADA 풍속의 설명력 차이를 고려할 때, 가장 좋은 개선 시나리오는 **그룹별 매핑 → 현장풍속 보정 → 파워커브 모델링** 순서입니다.